

Algoritmos y Estructuras de Datos III

Segundo cuatrimestre 2013

Técnicas de diseño de algoritmos

Técnicas de diseño de algoritmos

- ▶ Algoritmos golosos
- ▶ *Backtracking* (búsqueda con retroceso)
- ▶ *Divide and conquer* (dividir y conquistar)
- ▶ Recursividad
- ▶ Programación dinámica
- ▶ Algoritmos probabilísticos

Algoritmos golosos

Idea: Construir una solución seleccionando en cada paso la mejor alternativa, sin considerar (o haciéndolo débilmente) las implicancias de esta selección.

- ▶ Fáciles de inventar.
- ▶ Fáciles de implementar.
- ▶ Generalmente eficientes.
- ▶ Pero no siempre “funcionan”: algunos problemas no pueden ser resueltos por este enfoque.
 - ▶ Habitualmente, proporcionan **heurísticas** sencillas para **problemas de optimización**.
 - ▶ En general permiten construir soluciones razonables, pero sub-óptimas.
- ▶ Conjunto de candidatos.
- ▶ Función de selección.

Ejemplo: El problema de la mochila

Datos de entrada:

- ▶ Capacidad $C \in \mathbb{R}_+$ de la mochila (peso máximo).
- ▶ Cantidad $n \in \mathbb{N}$ de objetos.
- ▶ Peso $p_i \in \mathbb{R}_+$ del objeto i , para $i = 1, \dots, n$.
- ▶ Beneficio $b_i \in \mathbb{R}_+$ del objeto i , para $i = 1, \dots, n$.

Problema: Determinar qué objetos debemos incluir en la mochila sin excedernos del peso máximo C , de modo tal de **maximizar** el beneficio total entre los objetos seleccionados. En la versión más simple de este problema vamos a suponer que podemos poner parte de un objeto en la mochila.

Ejemplo: El problema de la mochila

Algoritmo(s) goloso(s): Mientras no se haya excedido el peso de la mochila, agregar a la mochila el objeto i que ...

- ▶ ... tenga mayor beneficio b_i .
- ▶ ... tenga menor peso p_i .
- ▶ ... maximice b_i/p_i .

Ejemplo: El problema de la mochila

Datos de entrada:

$$C = 100, n = 5$$

	1	2	3	4	5
p	10	20	30	40	50
b	20	30	66	40	60
b/p	2.0	1.5	2.2	1.0	1.2

- ▶ mayor beneficio b_i : $66 + 60 + 40/2 = 146$.
- ▶ menor peso p_i : $20 + 30 + 66 + 40 = 156$.
- ▶ maximice b_i/p_i : $66 + 20 + 30 + 0,8 \cdot 60 = 164$.

Ejemplo: El problema de la mochila

- ▶ ¿Qué podemos decir en cuanto a la **calidad** de las soluciones obtenidas por estos algoritmos?
- ▶ Se puede demostrar que la selección según se maximice b_i/p_i da una solución óptima.
- ▶ ¿Qué podemos decir en cuanto a su **complejidad**?
- ▶ ¿Qué sucede si los elementos se deben poner enteros en la mochila?

Ejemplo: Tiempo de espera total en un sistema

Problema: Un servidor tiene n clientes para atender, y los puede atender en cualquier orden. Para $i = 1, \dots, n$, el tiempo necesario para atender al cliente i es $t_i \in \mathbb{R}_+$. El objetivo es determinar en qué orden se deben atender los clientes para minimizar **la suma de los tiempos de espera** de los clientes.

Si $I = (i_1, i_2, \dots, i_n)$ es una permutación de los clientes que representa el orden de atención, entonces la suma de los tiempos de espera es

$$\begin{aligned} T &= t_{i_1} + (t_{i_1} + t_{i_2}) + (t_{i_1} + t_{i_2} + t_{i_3}) + \dots \\ &= \sum_{k=1}^n (n - k + 1) t_{i_k}. \end{aligned}$$

Ejemplo: Tiempo de espera total en un sistema

Algoritmo goloso: En cada paso, atender al cliente pendiente que tenga menor tiempo de atención.

- ▶ Retorna una permutación $I_{\text{GOL}} = (i_1, \dots, i_n)$ tal que $t_{i_j} \leq t_{i_{j+1}}$ para $j = 1, \dots, n-1$.
- ▶ ¿Cuál es la **complejidad** de este algoritmo?
- ▶ Este algoritmo proporciona la **solución óptima**!

Backtracking

Idea: Técnica para recorrer sistemáticamente todas las posibles configuraciones del espacio de soluciones de un problema computacional.

- ▶ Habitualmente, utiliza un **vector** $a = (a_1, a_2, \dots, a_n)$ para representar una solución candidata, cada a_i pertenece un dominio/conjunto ordenado y finito A_i .
- ▶ El espacio de soluciones es el producto cartesiano $A_1 \times \dots \times A_n$.
- ▶ En cada paso se extienden las soluciones parciales $a = (a_1, a_2, \dots, a_k)$, $k < n$, agregando un elemento más, $a_{k+1} \in S_{k+1} \subseteq A_{k+1}$, al final del vector a . Las nuevas soluciones parciales son sucesores de la anterior.
- ▶ Si S_{k+1} es vacío, se *retrocede* a la solución parcial $(a_1, a_2, \dots, a_{k-1})$.

Backtracking

- ▶ Se puede pensar este espacio como un árbol dirigido, donde cada vértice representa una solución parcial y un vértice x es hijo de y si la solución parcial x se puede extender desde la solución parcial y .
- ▶ Permite descartar configuraciones antes de explorarlas (podar el árbol).

Backtracking: Esquema General - Todas las soluciones

```
algoritmo  $BT(a, k)$ 
  si  $a$  es solución entonces
    procesar( $a$ )
    retornar
  sino
    para cada  $a' \in \text{Sucesores}(a, k)$ 
       $BT(a', k + 1)$ 
    fin para
  fin si
  retornar
```

Backtracking: Esquema General - Una solución

```
algoritmo  $BT(a, k)$ 
  si  $a$  es solución entonces
     $sol \leftarrow a$ 
     $encontro \leftarrow \text{true}$ 
  sino
    para cada  $a' \in \text{Sucesores}(a, k)$ 
       $BT(a', k + 1)$ 
      si  $encontro$  entonces
        retornar
      fin si
    fin para
  fin si
retornar
```

- ▶ sol variable global que guarda la solución.
- ▶ $encontro$ variable booleana global que indica si ya se encontró una solución. Inicialmente está en **false**.

Ejemplo: Problema de las 8 reinas

Ubicar 8 reinas en el tablero de ajedrez (8×8) sin que ninguna “amenace” a otra.

- ▶ ¿Cuántas combinaciones del tablero hay que considerar?

$$64^8 \approx 10^{14}$$

- ▶ Sabemos que dos reinas no pueden estar en el mismo casillero.

$$\binom{64}{8} = 442616536$$

- ▶ Sabemos que cada fila debe tener exactamente una reina. Cada solución parcial puede estar representada por (a_1, \dots, a_k) , $k \leq 8$, con $a_i \in \{1, \dots, 8\}$ indicando la columna de la reina que está en la fila i .

Tenemos ahora $8^8 = 16777216$ combinaciones.

Ejemplo: Problema de las 8 reinas

- ▶ Es más, una misma columna debe tener exactamente una reina.

Se reduce a $8! = 40320$ combinaciones.

- ▶ ¿Cómo chequear un vector a es una solución?

$$a_i - a_j \notin \{i - j, 0, j - i\}, \forall i, j \in \{1, \dots, 8\} \text{ e } i \neq j.$$

- ▶ Ahora estamos en condición de implementar un algoritmo para resolver el problema!
- ▶ ¿Cómo generalizar para el problema de n reinas?

Divide and conquer

- ▶ Si la instancia I de entrada es pequeña, entonces utilizar un algoritmo ad hoc para el problema.
- ▶ En caso contrario:
 - ▶ **Dividir** I en sub-instancias I_1, I_2, \dots, I_k más pequeñas.
 - ▶ Resolver **recursivamente** las k sub-instancias.
 - ▶ **Combinar** las soluciones para las k sub-instancias para obtener una solución para la instancia original I .

Ejemplo: Mergesort

Algoritmo *divide and conquer* para ordenar un arreglo A de n elementos (von Neumann, 1945).

- ▶ Si n es pequeño, ordenar por cualquier método sencillo.
- ▶ Si n es grande:
 - ▶ $A_1 :=$ primera mitad de A .
 - ▶ $A_2 :=$ segunda mitad de A .
 - ▶ Ordenar recursivamente A_1 y A_2 por separado.
 - ▶ Combinar A_1 y A_2 para obtener los elementos de A ordenados (apareo de arreglos).

Este algoritmo contiene todos los elementos típicos de la técnica *divide and conquer*.

Ejemplo: Mergesort

Algoritmo *divide and conquer* para ordenar un arreglo A de n elementos (von Neumann, 1945).

- ▶ Si n es pequeño, ordenar por cualquier método sencillo.
- ▶ Si n es grande:
 - ▶ $A_1 :=$ primera mitad de A .
 - ▶ $A_2 :=$ segunda mitad de A .
 - ▶ Ordenar recursivamente A_1 y A_2 por separado.
 - ▶ Combinar A_1 y A_2 para obtener los elementos de A ordenados (apareo de arreglos).

Este algoritmo contiene todos los elementos típicos de la técnica *divide and conquer*.

Ejemplo: Multiplicación de Strassen

- ▶ Sean $A, B \in \mathbb{R}^{n \times n}$. El algoritmo estándar para calcular AB tiene una complejidad de $\Theta(n^3)$.
- ▶ Durante muchos años se pensaba que esta complejidad era **óptima**.
- ▶ Sin embargo, Strassen (1969) pateó el tablero. Particionamos:

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}, \quad B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}.$$

Ejemplo: Multiplicación de Strassen

Definimos:

$$\begin{aligned} M_1 &= (A_{21} + A_{22} - A_{11})(B_{22} - B_{12} + B_{11}) \\ M_2 &= A_{11}B_{11} \\ M_3 &= A_{12}B_{21} \\ M_4 &= (A_{11} - A_{21})(B_{22} - B_{12}) \\ M_5 &= (A_{21} + A_{22})(B_{12} - B_{11}) \\ M_6 &= (A_{12} - A_{21} + A_{11} - A_{22})B_{22} \\ M_7 &= A_{22}(B_{11} + B_{22} - B_{12} - B_{21}). \end{aligned}$$

Entonces,

$$AB = \begin{pmatrix} M_2 + M_3 & M_1 + M_2 + M_5 + M_6 \\ M_1 + M_2 + M_4 - M_7 & M_1 + M_2 + M_4 + M_5 \end{pmatrix}.$$

Ejemplo: Multiplicación de Strassen

- ▶ Este algoritmo permite calcular el producto AB en tiempo $O(n^{\log_2(7)}) = O(n^{2,81})$ (!).
- ▶ Requiere 7 multiplicaciones de matrices de tamaño $n/2 \times n/2$, en comparación con las 8 multiplicaciones del algoritmo estándar.
- ▶ La cantidad de sumas (y restas) de matrices es mucho mayor.
- ▶ El algoritmo asintóticamente más eficiente conocido a la fecha tiene una complejidad de $O(n^{2,376})$ (Coppersmith y Winograd, 1987).

Programación Dinámica

- ▶ Al igual que “dividir y conquistar”, el problema es dividido en subproblemas de tamaños menores que son más fácil de resolver. Una vez resueltos estos subproblemas, se combinan las soluciones obtenidas para generar la solución del problema original.
- ▶ Es **bottom up** y no es recursivo.
- ▶ Se guardan las soluciones de los subproblemas para no calcularlos más de una vez.
- ▶ **Principio de optimalidad**: un problema de optimización satisface el principio de optimalidad de Bellman si en una sucesión óptima de decisiones o elecciones, cada subsucesión es a su vez óptima. Es decir, si miramos una subsolución de la solución óptima, debe ser solución del subproblema asociado a esa subsolución. Es condición necesaria para poder usar la técnica de programación dinámica.
 - ▶ Se cumple en camino mínimo (sin distancias negativos).
 - ▶ No se cumple en camino máximo.

Programación Dinámica: ejemplos

- ▶ Coeficientes binomiales $\binom{n}{k}$
- ▶ Producto de matrices
- ▶ Mochila 0/1.
- ▶ Subsecuencia creciente máxima
- ▶ Comparación de secuencias de ADN

Coeficientes binomiales

$$\binom{n}{k} = \begin{cases} 1 & \text{si } k = 0 \text{ o } k = n \\ \binom{n-1}{k-1} + \binom{n-1}{k} & \text{si } 0 < k < n \\ 0 & \text{caso contrario} \end{cases}$$

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1		1					
3	1			1				
4	1				1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1			1				
4	1				1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3		1				
4	1				1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3	3	1				
4	1				1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3	3	1				
4	1	4			1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3	3	1				
4	1	4	6		1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3	3	1				
4	1	4	6	4	1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

	0	1	2	3	4	...	$k-1$	k
0	1							
1	1	1						
2	1	2	1					
3	1	3	3	1				
4	1	4	6	4	1			
\vdots	\vdots					\ddots		
$k-1$	1						1	
k	1							1
\vdots	\vdots							
$n-1$	1							
n	1							

Coeficientes binomiales

algoritmo *combinatorio*(n, k)

entrada: dos enteros n y k

salida: $\binom{n}{k}$

para $i = 1$ **hasta** n **hacer**

$A[i][0] \leftarrow 1$

fin para

para $j = 0$ **hasta** k **hacer**

$A[j][j] \leftarrow 1$

fin para

para $i = 2$ **hasta** n **hacer**

para $j = 2$ **hasta** $\min(i - 1, k)$ **hacer**

$A[i][j] \leftarrow A[i - 1][j - 1] + A[i - 1][j]$

fin para

fin para

retornar $A[n][k]$

Coeficientes binomiales

► Función recursiva (“dividir y conquistar”):

 ► Complejidad $\Omega(\binom{n}{k})$.

► Programación dinámica:

 ► Complejidad $O(nk)$.

 ► Espacio $\Theta(k)$: sólo necesitamos almacenar la fila anterior de la que estamos calculando.

Multiplicación de n matrices

$$M = M_1 \times M_2 \times \dots M_n$$

Por la propiedad asociativa del producto de matrices esto puede hacerse de muchas formas. Queremos determinar la que minimiza el número de operaciones necesarias. Por ejemplo: las dimensiones de A es de 13×5 , B de 5×89 , C de 89×3 y D de 3×34 .

Tenemos

- $((AB)C)D$ requiere 10582 multiplicaciones.
- $(AB)(CD)$ requiere 54201 multiplicaciones.
- $(A(BC))D$ requiere 2856 multiplicaciones.
- $A((BC)D)$ requiere 4055 multiplicaciones.
- $A(B(CD))$ requiere 26418 multiplicaciones.

Multiplicación de n matrices

- La mejor forma de multiplicar todas las matrices es multiplicar las matrices 1 a i por un lado y las matrices $i + 1$ a n por otro lado y luego multiplicar estos dos resultados para algún $1 \leq i \leq n - 1$.
- En la solución óptima de $M = M_1 \times M_2 \times \dots M_n$, estos dos subproblemas, $M_1 \times M_2 \times \dots M_i$ y $M_{i+1} \times M_{i+2} \times \dots M_n$ deben estar resueltos de forma óptima: se cumple el principio de optimalidad.
- Llamamos $m[i][j]$ solución del subproblema $M_i \times M_{i+1} \times \dots M_j$, es decir la cantidad mínima de multiplicaciones necesarias para calcular $M_i \times M_{i+1} \times \dots M_j$.

Multiplicación de n matrices

Suponemos que las dimensiones de las matrices están dadas por un vector $d \in N^{n+1}$, tal que la matriz M_i tiene $d[i - 1]$ filas y $d[i]$ columnas para $1 \leq i \leq n$. Entonces:

- ▶ Para $i = 1, 2, \dots, n$, $m[i][i] = 0$
- ▶ Para $i = 1, 2, \dots, n - 1$, $m[i][i + 1] = d[i - 1]d[i]d[i + 1]$
- ▶ Para $s = 2, \dots, n - 1$, $i = 1, 2, \dots, n - s$,
$$m[i][i+s] = \min_{i \leq k < i+s} (m[i][k] + m[k+1][i+s] + d[i-1]d[k]d[i+s])$$

La solución del problema es $m[1][n]$.

Multiplicación de n matrices

- ▶ ¿Algoritmo?
- ▶ ¿Complejidad?

Algoritmos probabilísticos

- ▶ Cuando un algoritmo tiene que hacer una elección a veces es preferible elegir al azar en vez de gastar mucho tiempo tratando de ver cual es la mejor elección.
- ▶ Algoritmos numéricos: dan una respuesta aproximada.
 - ▶ + tiempo proceso \Rightarrow + precisión
 - ▶ ejemplo: cálculo de integral
- ▶ Algoritmos de Monte Carlo: con alta probabilidad dan una respuesta es exacta.
 - ▶ + tiempo proceso \Rightarrow + probabilidad de acertar
 - ▶ ejemplo: determinar la existencia de un elemento mayor en un arreglo

Algoritmos probabilísticos

- ▶ Algoritmos Las Vegas: si da respuesta es correcta pero puede no darla.
 - ▶ + tiempo proceso \Rightarrow + probabilidad de obtener la respuesta
 - ▶ ejemplo: problema de 8 reinas
- ▶ Algoritmos Sherwood: randomiza un algoritmo determinístico donde hay una gran diferencia entre el peor caso y caso promedio. Elimina la diferencia entre buenas y malas instancias.
 - ▶ quicksort